



南開大學
Nankai University

计算机学院

深度学习及应用（高阶课）实验报告

对抗生成网络算法

姓名：申健强

学号：2313119

专业：计算机科学与技术

2026 年 6 月 29 日

目录

1 实验目的与要求	2
2 数据集与实验设置	2
3 模型结构与原理	2
3.1 GAN 的对抗训练原理	2
3.2 全连接 GAN	2
3.3 卷积 DCGAN	3
4 实验结果	3
4.1 训练对比: FC-GAN 与 DCGAN	3
4.2 DCGAN 与 CelebA 扩展	4
5 分析与讨论	4
5.1 随机数调整对生成结果的影响	6
5.2 GAN 的模式崩溃问题	8
6 结论	8

1 实验目的与要求

本实验的目标是掌握生成对抗网络 (GAN) 的基本原理, 并使用 PyTorch 在 **FashionMNIST** 数据集上完成图像生成任务。具体要求:

- 掌握 GAN 的对抗训练原理;
- 使用 PyTorch 搭建 GAN (全连接实现) 训练 FashionMNIST, 给出生成器/判别器的模型结构与训练 loss 曲线;
- 自定义一组随机数, 生成 8 张图;
- 针对自定义的 100 维随机噪声, 自由挑选 5 个维度, 每个维度调整 3 次取值, 生成 15×8 张图, **重点总结与解释调整随机数对生成结果的影响**;
- 用卷积实现生成器和判别器 (DCGAN)。

2 数据集与实验设置

数据集. FashionMNIST 训练集共 60000 张 28×28 灰度服饰图像 (T 恤、裤子、套衫、连衣裙、外套、凉鞋、衬衫、运动鞋、包、短靴共 10 类)。预处理仅做 `ToTensor` 并归一化到 $[-1, 1]$, 与生成器输出端的 `Tanh` 范围匹配。

训练设置. 噪声维度 $z_dim = 100$, 批大小 128, 优化器 Adam (学习率 2×10^{-4} , $\beta = (0.5, 0.999)$, DCGAN 论文推荐设置), 损失为 `BCELoss`, 全连接 GAN 与卷积 DCGAN 各训练 20 个 epoch (GPU), 随机种子固定为 42 以保证可复现。模型定义在 `models.py`, 数据/训练/生成/潜变量扰动等工具在 `train_utils.py`, 训练时记录每个 epoch 的 G/D 损失与判别器对真图、假图的平均输出 $D(x)$ 、 $D(G(z))$ 用于分析。

3 模型结构与原理

3.1 GAN 的对抗训练原理

GAN 由生成器 G 与判别器 D 两个相互博弈的网络组成: G 接收服从标准正态分布的噪声 z , 输出一张与真实数据同尺寸的图像 $G(z)$; D 接收一张图像, 输出其来自真实数据的概率。 D 希望把真图判为 1、假图判为 0, 而 G 希望自己生成的图被 D 判为真, 二者构成 min-max 优化问题:

$$\min_G \max_D V(D, G) = \mathbb{E}_{\mathbf{x} \sim p_{data}} [\log D(\mathbf{x})] + \mathbb{E}_{\mathbf{z} \sim p_z} [\log (1 - D(G(\mathbf{z})))] \quad (1)$$

训练时交替进行两步: (1) 固定 G , 用一批真图 (标签 1) 和一批生成的假图 (标签 0, 对 G 的输出 `detach`) 以 BCE 损失更新 D ; (2) 固定 D , 以“假图标签为 1”计算 BCE 更新 G , 即采用非饱和损失 $-\log D(G(z))$ 代替 $\log(1 - D(G(z)))$, 缓解训练初期的梯度消失。理论均衡点处 $p_G = p_{data}$, D 对任意输入输出 0.5。

3.2 全连接 GAN

生成器与判别器均为三层全连接网络 (在老师提供的两层版本基础上加宽加深, 并在 G 中加入 BatchNorm 以稳定训练): `print(net)` 输出如下 (为简洁略去 BatchNorm 的默认超参):

```

1 FCGenerator( # 560,656 params          FCDiscriminator( # 233,985 params
2   (net): Sequential(                   (net): Sequential(
3     (0): Linear(100, 256, bias=True)    (0): Linear(784, 256, bias=True)
4     (1): LeakyReLU(0.2, inplace=True)   (1): LeakyReLU(0.2, inplace=True)
5     (2): Linear(256, 512, bias=True)     (2): Linear(256, 128, bias=True)
6     (3): BatchNorm1d(512)               (3): LeakyReLU(0.2, inplace=True)
7     (4): LeakyReLU(0.2, inplace=True)   (4): Linear(128, 1, bias=True)
8     (5): Linear(512, 784, bias=True)    (5): Sigmoid() ) # -> P(real)
9     (6): Tanh() ) ) # -> (1,28,28),[-1,1]

```

3.3 卷积 DCGAN

按 DCGAN 的设计原则：生成器用**转置卷积**逐步上采样 ($1 \times 1 \rightarrow 7 \times 7 \rightarrow 14 \times 14 \rightarrow 28 \times 28$)，判别器用**步长为 2 的卷积**代替池化逐步下采样，均配合 BatchNorm；权重按论文初始化为 $\mathcal{N}(0, 0.02)$ ；`print(net)` 输出如下（BatchNorm/激活合并行、空间尺寸见上文）：

```

1 DCGenerator( # 1,781,504 params
2   (net): Sequential(
3     (0): ConvTranspose2d(100, 256, kernel_size=(7,7), stride=(1,1), bias=False)
4     (1): BatchNorm2d(256) (2): ReLU(inplace=True)
5     (3): ConvTranspose2d(256, 128, kernel_size=(4,4), stride=(2,2), padding=(1,1), bias=False)
6     (4): BatchNorm2d(128) (5): ReLU(inplace=True)
7     (6): ConvTranspose2d(128, 1, kernel_size=(4,4), stride=(2,2), padding=(1,1), bias=False)
8     (7): Tanh() ) )
9 DCDiscriminator( # 138,624 params
10   (net): Sequential(
11     (0): Conv2d(1, 64, kernel_size=(4,4), stride=(2,2), padding=(1,1), bias=False)
12     (1): LeakyReLU(0.2, inplace=True)
13     (2): Conv2d(64, 128, kernel_size=(4,4), stride=(2,2), padding=(1,1), bias=False)
14     (3): BatchNorm2d(128) (4): LeakyReLU(0.2, inplace=True)
15     (5): Conv2d(128, 1, kernel_size=(7,7), stride=(1,1), bias=False) (6): Sigmoid() ) )

```

4 实验结果

4.1 训练对比：FC-GAN 与 DCGAN

两套模型各训练 20 个 epoch，损失曲线与判别器输出见图 4.1。两者的 G/D 损失都呈**拉锯而非单调下降**，判别器输出最终都落在 0.5 两侧（FC: $D(x)/D(G(z)) = 0.57/0.44$ ，DC: $0.59/0.41$ ）、接近理论均衡点，全程没有任何一方崩塌；其中 **DCGAN** 的 $D(x)/D(G(z))$ 由 $0.75/0.27$ **双向收敛**到 0.5 附近，最为典型。




图 4.1: FC-GAN (左) 与 DCGAN (右) 的训练损失 (实线) 与判别器输出 $D(x)$ 、 $D(G(z))$ (虚线, 向 0.5 收敛), 表明对抗训练健康。

4.2 DCGAN 与 CelebA 扩展

DCGAN 以相同设置训练 20 个 epoch (损失见图 4.1 右), 一组随机噪声下生成质量明显高于全连接版本, 定量与可视化对比见第 5 节。为检验框架可扩展性, 我们另在 **CelebA** (202,599 张人脸, 64×64 RGB) 上训练 5 个 epoch 的加深版 DCGAN (5 层卷积/转置卷积), 生成的人脸已能呈现大致五官布局与肤色光影 (图 4.2; 5 epoch 仍偏粗糙、局部有扭曲), 说明同一套对抗训练框架可迁移到更高分辨率的彩色图像。




图 4.2: CelebA 上 DCGAN 的真实人脸 (左) 与生成人脸 (右), 5 epoch。

5 分析与讨论

表 1 汇总全连接 GAN 与 DCGAN 的最终指标, 图 5.3 用同一组 16 个噪声直观对比二者的生成质量。

表 1: 全连接 GAN 与 DCGAN 对比 (第 20 epoch 的 epoch 均值)

模型	G 参数量	D 参数量	G loss	D loss	$D(x) / D(G(z))$
全连接 GAN	560,656	233,985	1.008	1.237	0.566 / 0.437
DCGAN (卷积)	1,781,504	138,624	1.108	1.181	0.587 / 0.413




图 5.3: 生成质量对比。上: 真实图 / FC-GAN / DCGAN (FC 与 DC 用同一组 16 个噪声); 下: 同一噪声的中心局部放大——FC-GAN 边缘颗粒噪点明显, DCGAN 锐利平滑。

两者的损失数值相近——这是对抗损失的特点, 它衡量的是博弈状态而非绝对生成质量——但**视觉质量差距显著**: DCGAN 生成的衣物边缘锐利、明暗过渡自然、几乎没有椒盐噪点, 裤腿、鞋型、衣领等局部结构清晰; FC-GAN 则普遍带有颗粒噪声、轮廓发虚。原因在于卷积结构的**空间归纳偏置**: 转置卷积的局部感受野与权重共享让相邻像素天然相关, 生成图像局部平滑、结构连贯; 而全连接层把 784 个像素当作彼此独立的输出维度, 必须靠数据“硬学”像素间的空间相关性, 因此更容易出现噪点。

从生成器内部看卷积的作用. 进一步可视化 DCGAN 生成器的中间特征图 (图 5.4): 噪声 z 先被转置卷积投影成 256 个 7×7 的**粗特征** (勾勒大致轮廓与布局), 再经两层 stride-2 转置卷积上采样为 128 个 14×14 的**中层特征** (细化边缘与局部结构), 最后合成 28×28 的图像。这种“由粗到细、逐级上采样”的合成过程正是卷积生成器优于全连接的本质: 空间结构是**逐层、局部地**被构造出来的, 而非由全连接层一次性把每个像素独立预测出来。

DCGAN generator: transpose-conv upsamples z from coarse 7×7 features to a fine 28×28 image (8 of each stage's channels shown)




图 5.4: DCGAN 生成器中间特征图: $z \rightarrow 7 \times 7$ (256 通道, 粗轮廓) $\rightarrow 14 \times 14$ (128 通道, 细化) $\rightarrow 28 \times 28$ 输出 (各阶段展示 8 个通道)。

5.1 随机数调整对生成结果的影响

固定随机种子 123 采样 8 个 100 维标准正态噪声，生成结果见图 5.5(a)：可辨认出包、裤子、套衫、鞋等类别，整体轮廓正确但边缘有颗粒噪点（全连接缺乏空间归纳偏置的典型表现）。以这 8 个噪声为基准（对应 8 列），从 100 维中挑选第 $\{5, 25, 45, 65, 85\}$ 共 5 个维度、每维取 $\{-2.5, 0, +2.5\}$ 三档（其余 99 维不变），得到图 5.5(b) 的 15×8 扰动网格（每 3 行一组对应一个维度）。逐维观察可归纳出三点现象（成因见下文）：单维扰动引起整张图的**整体渐变**而非孤立属性变化；基准噪声决定类别、单维扰动多在类内形变，仅在 ± 2.5 时偶尔把样本推过类别边界（鞋 $\leftrightarrow$ 靴过渡）；幅度越大变化越剧烈、噪点越多，不同维度作用方向也各不相同。




图 5.5: (a) 8 个自定义噪声样本；(b) 以同样 8 个噪声为列的 15×8 潜变量扰动（每 3 行一组对应一个维度，组内取值 $-2.5/0/+2.5$ ）。

结合 15×8 扰动实验，对”调整随机数如何影响生成结果”总结如下：

- **噪声 z 是生成图像唯一的信息来源**，其整体位置决定生成什么。生成器学到的是从 100 维标准正态分布到图像流形的连续映射 $G: \mathbb{R}^{100} \rightarrow \mathbb{R}^{28 \times 28}$ 。8 个基准噪声落在流形的不同区域，因此分别对应包、裤子、套衫、鞋等不同类别——”类别”这一最主要的语义由 z 的整体位置决定，而非某一维单独决定。
- **普通 GAN 的潜空间是纠缠的**：单个维度不对应单个语义属性。实验中调整任何一维，都观察到

亮度、形状、纹理的**联动渐变**，找不到一个只控制袖长或只控制明暗的维度。这是因为标准 GAN 的训练目标只要求生成分布逼近数据分布，对潜空间的组织方式没有任何约束，各语义因子自然地以混合的方式分布在所有维度上（这正是 InfoGAN、StyleGAN 等后续工作引入解耦约束的动机）。

- **G 是连续映射，因此扰动带来的是平滑过渡。**取值从 -2.5 经 0 到 $+2.5$ ，图像呈连续形变而非跳变；只有当扰动把 z 推过两个类别在潜空间中的边界时，才会看到鞋 $\leftrightarrow$ 靴这类离散类别切换，且切换附近往往出现“两类之间”的模糊形态。
- **扰动幅度与生成质量的关系印证了训练分布的作用。** $|z_d| \leq 1$ 附近（标准正态的高密度区）生成质量最好；取到 ± 2.5 时图像变化剧烈且噪点增多，因为训练时几乎采不到这些低密度区域的样本，生成器在那里的映射没有得到充分学习。
- **同一维度对不同基准噪声的影响不同。**这说明 G 学到的映射是高度非线性的：某一维的“语义方向”依赖于 z 所处的局部邻域，在流形的不同区域，同一坐标轴方向对应不同的图像变化。

潜空间插值与截断：另外两种“调随机数”的视角。除单维扰动外，我们再用两种方式考察噪声的影响（图 5.6，用 DCGAN 生成）。**球面插值：**在两个随机噪声之间做球面线性插值，生成结果**平滑地**从一种衣物过渡到另一种、没有突兀跳变——直观证明 G 是从噪声到图像的连续映射。**截断技巧：**把噪声整体乘以系数 σ ， σ 越小（采样越集中于分布中心）生成越规整但越雷同（保真度高、多样性低）， σ 越大越多样但畸变与噪点增多——这与上面“高密度区质量好、低密度区质量差”的结论互相印证，也是 BigGAN 等工作中“截断换保真”技巧的由来。

(a) Spherical interpolation between two random noise vectors (left $\rightarrow$ right): the generator is a smooth, continuous map



(b) Truncation: scaling the noise by σ (top $\rightarrow$ bottom: 0.2, 0.5, 1.0, 1.5, 2.0) trades diversity for fidelity



图 5.6: 随机数影响的另外两种视角 (DCGAN)。(a) 两个噪声间的球面插值：生成图像连续过渡，说明 G 是连续映射；(b) 噪声幅度 σ 由小到大：保真度与多样性此消彼长。

此外，本实验对 GAN 的训练动态也有直观体会：判别器输出 $D(x)$ 、 $D(G(z))$ 最终都在 0.5 两侧 (DCGAN 尤其呈清晰的双向收敛)、损失曲线呈拉锯而非单调下降，是对抗训练健康进行的标志；而

DCGAN 与 FC-GAN 损失数值接近、视觉质量却差距明显，提醒我们对抗损失不能直接当作生成质量的度量，结构先验（卷积）对生成图像质量起着决定性作用。

5.2 GAN 的模式崩溃问题

在 GAN 对抗生成时常会遇到模式崩溃问题，模式崩溃（mode collapse）指生成器只学会产出少数几种样本、覆盖不了真实数据的全部模态。其根源在于 GAN 的极小极大博弈：生成器的目标只是“骗过当前判别器”，一旦它找到某几个能稳定骗过 D 的输出，就会把大量不同的噪声 z 都映射到这几个输出上，从而丢失多样性；当 D 与 G 的更新失衡（如 D 过弱、学习率不当）或缺乏稳定化手段时尤其容易发生。

为直观展示，我们在相同数据上训练两个全连接 GAN：一个采用**健康设置**（生成器带 BatchNorm、 G/D 学习率平衡、1:1 更新），另一个去掉生成器 BatchNorm、判别器学习率调低且每步多更新生成器故意制造失衡。训练后各采样 2000 张，用一个在 FashionMNIST 上训练的小型 CNN 分类器统计生成样本落入 10 个类别的分布（图 5.7）。结果非常清晰：健康模型的生成样本覆盖全部 10 类（类别分布熵 2.16，接近均匀上限 $\ln 10 \approx 2.30$ ）；崩溃模型则几乎只生成 **Sandal 与 Shirt 两类**（熵骤降到 0.68），其余 8 类几乎从不出现——这正是模式崩溃的典型表现，且生成质量也随之劣化。




图 5.7: 模式崩溃演示。(a) 健康 GAN 样本；(b) 崩溃 GAN 样本；(c) 用 FashionMNIST 分类器统计的生成类别分布——健康模型覆盖 10 类（熵 2.16），崩溃模型几乎只产出 2 类（熵 0.68）。

缓解模式崩溃的主要思路包括：(1) **改进损失/距离度量**，如 WGAN、WGAN-GP 以 Wasserstein 距离提供更平滑、不易饱和的梯度；(2) **让判别器“看到”批内多样性**，如 minibatch discrimination、feature matching，使 D 能惩罚“整批雷同”；(3) **稳定化训练技巧**，如谱归一化（spectral norm）、双时间尺度更新（TTUR）、单边标签平滑、给 D 输入加噪；(4) **结构与更新平衡**，保持 G/D 容量与更新频率匹配、生成器使用 BatchNorm。

6 结论

本次实验我们在 FashionMNIST 上实现并对比了全连接 GAN 与卷积 DCGAN，并围绕随机数对生成的影响和模式崩溃两个重点展开探究与讨论。主要结论有三：其一，两套模型的 $D(x)$ 、 $D(G(z))$

最终都落在 0.5 两侧 (DCGAN 双向收敛尤为明显), 对抗博弈健康, 但损失数值相近、视觉质量却差距明显, 说明**对抗损失不能直接当作生成质量的度量**, 卷积的空间归纳偏置更可能是 DCGAN 质量更优的原因。其二, 噪声 z 是生成的唯一信息来源: 其整体位置决定生成类别, 单维扰动引起整体的平滑渐变而非独立属性变化, 普通 GAN 的潜空间高度**纠缠**, 插值与截断实验进一步印证了 G 是连续映射、且高密度区生成质量更好。其三, 通过失衡训练复现了**模式崩溃**, 并讨论了 WGAN-GP、minibatch discrimination、谱归一化等对策。

参考文献

- [1] I. Goodfellow, J. Pouget-Abadie, M. Mirza, et al. Generative Adversarial Nets. *NeurIPS*, 2014.
- [2] A. Radford, L. Metz, S. Chintala. Unsupervised Representation Learning with Deep Convolutional Generative Adversarial Networks. *ICLR*, 2016.
- [3] H. Xiao, K. Rasul, R. Vollgraf. Fashion-MNIST: a Novel Image Dataset for Benchmarking Machine Learning Algorithms. *arXiv:1708.07747*, 2017.
- [4] N. Inkawhich. DCGAN Tutorial. PyTorch Tutorials.